Projekt 2: Uczenie preferencji

Paviel Mamchur (154978), Krzysztof Garsztka (155954)

1. XGBoost

1.1 Wizualizacja

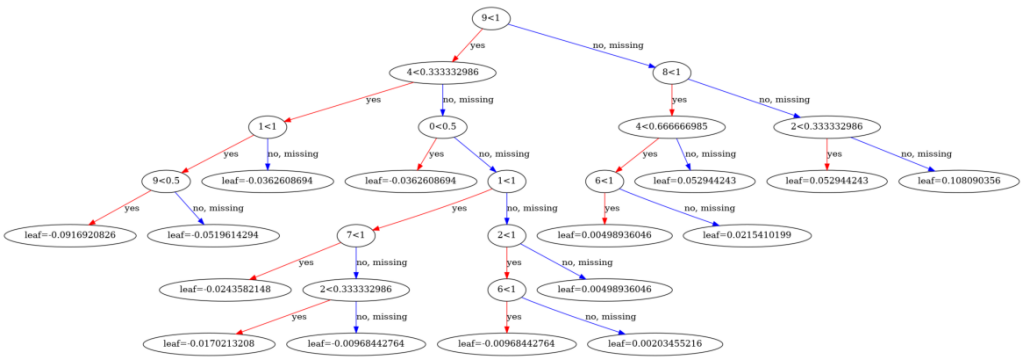

Figure 1: Wizualizacja drzewa decyzyjnego (wartości nie da się zaokrąglić)

1.2 Wyjaśnienie wybranych decyzji

Miary jakości nie są najlepsze, szczególnie biorąc pod uwagę to, że jest to klasyfikacja binarna, co sprawia że wyniki są nie dużo lepsze od algorytmu losowego. Wynika to ze specyfiki modelu, narzuconą przez parametry czyniące go bardzie interpretowalnym (jak np. tylko 1 drzewo).

$$\text{Accuracy}_{\text{train}} = 0.6074$$

$$\text{F1}_{\text{train}} = 0.6364$$

$$\text{AUC}_{\text{train}} = 0.6069$$

$$\text{Accuracy}_{\text{test}} = 0.3415$$

$$\text{F1}_{\text{test}} = 0.3415$$

$$\text{AUC}_{\text{test}} = 0.3588$$

#	1	2	3	4	5	6	7	8	9	10
1	0.5	1.0	1.0	0.0	0.6667	1.0	0.5	0.0	0.5	0.5
2	0.5	0.5	0.3333	1.0	0.3333	1.0	0.5	1.0	0.0	0.5
3	0.5	1.0	0.6667	0.5	1.0	0.0	1.0	0.5	1.0	0.0

Table 1: Przykładowe 3 warianty wraz z ocenami na kryteriach (numery kryteriów przesunięte o 1)

Najbardziej dyskryminującym jest kryterium 10, które się znajduje w korzeniu drzewa – wszystkie liście w prawym poddrzewie należą do klasy 1, a większość liści w lewym poddrzewie – do klasy 0. Natomiast, w wariantach referencyjnych ocena na kryterium 10 jest zawsze mniejsza od 10, więc nie wybieramy tego kryterium do zmiany. Podobna logika się aplikuje do kryterium 5. Żeby zmienić przynależność do klasy wariantu 1 wystarczy obniżyć jego wartość na kryterium 2 (np. o 0.1). Wtedy predykcja modelu zmieni się z klasy 1 do 0. Identyczna zmiana spowwoduje przejście z klasy 1 do 0 dla wariantu 3. Obniżając wartość na kryterium 4 dla wariantu 2 o 0.1 również spowodujemy przejście do gorszej klasy. Próbkując przestrzeń, uzyskujemy podobne wyniki – wystarczy obniżyć wartości tych kryteriów nawet o 0.01. Nie są to jedyne kryteria, które można zmienić, żeby przenieść warianty do innej klasy. Natomiast są to najbardziej sensowne zmiany zgodne z wykresem SHAP, ponieważ odpowiadają zmianom na kryteriach, które mają relatywnie największy wpływ na model (biorąc też pod uwagę wielkość zmian).

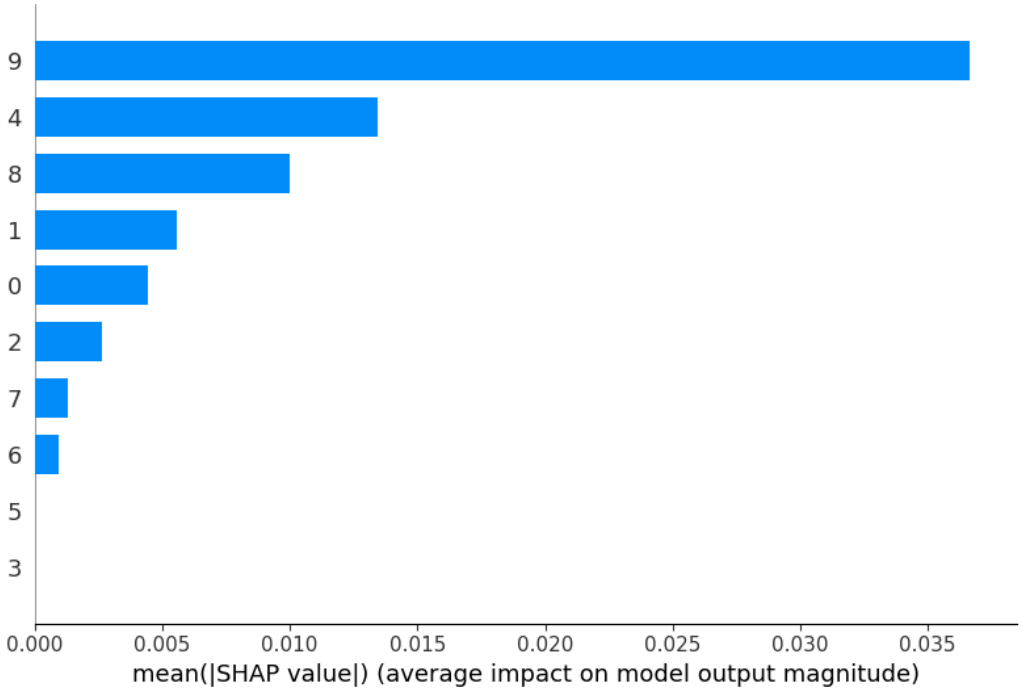

Figure 2: SHAP summary plot dla drzewa XGBoost

1.3 Interpretacja modelu

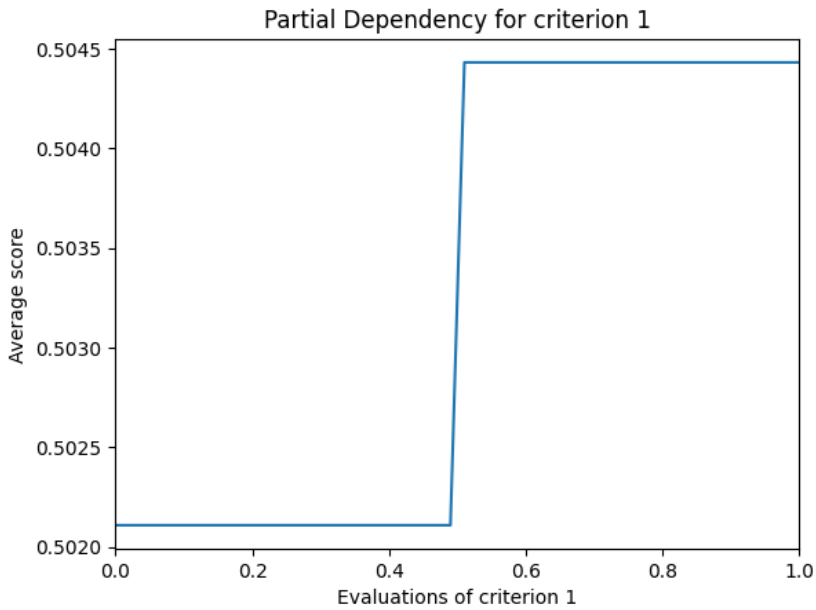

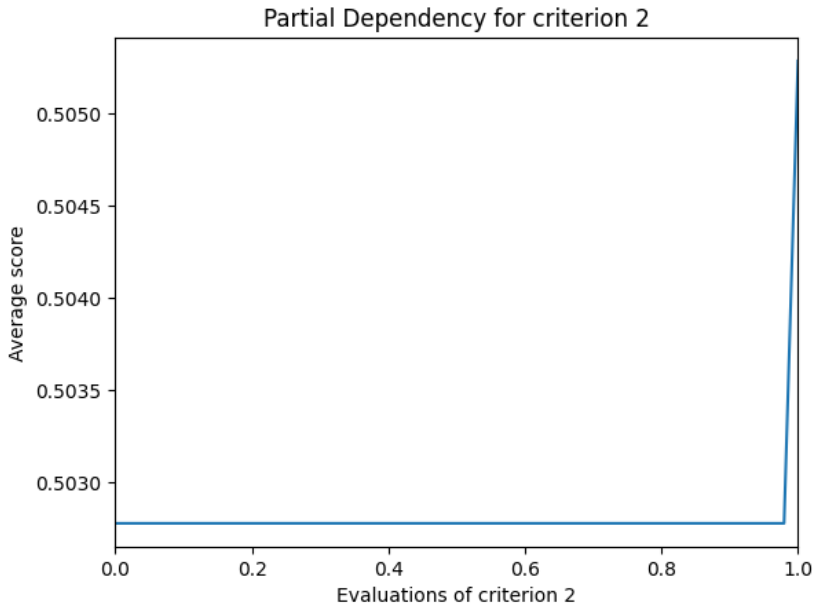

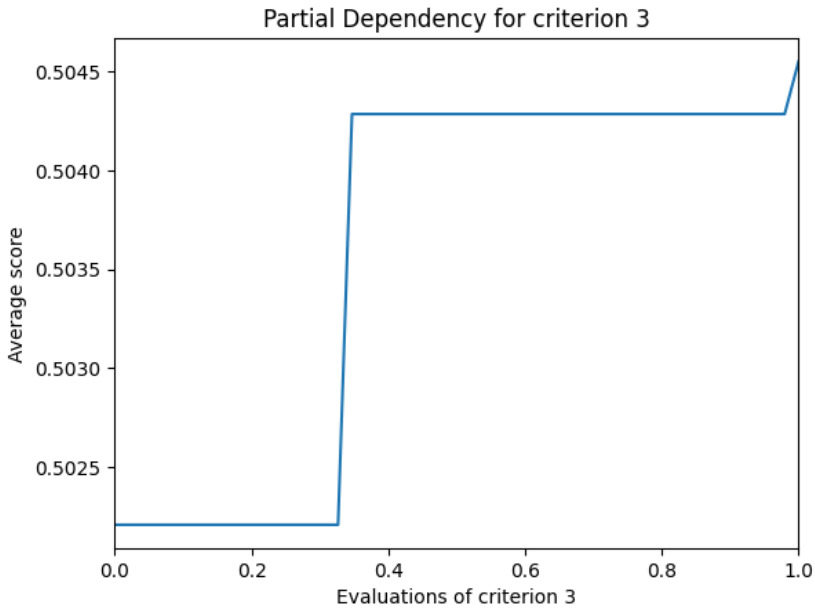
Partial Dependency for criterion 3
Average score
0.5045
0.5040
0.5035
0.5030
0.5025
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 3

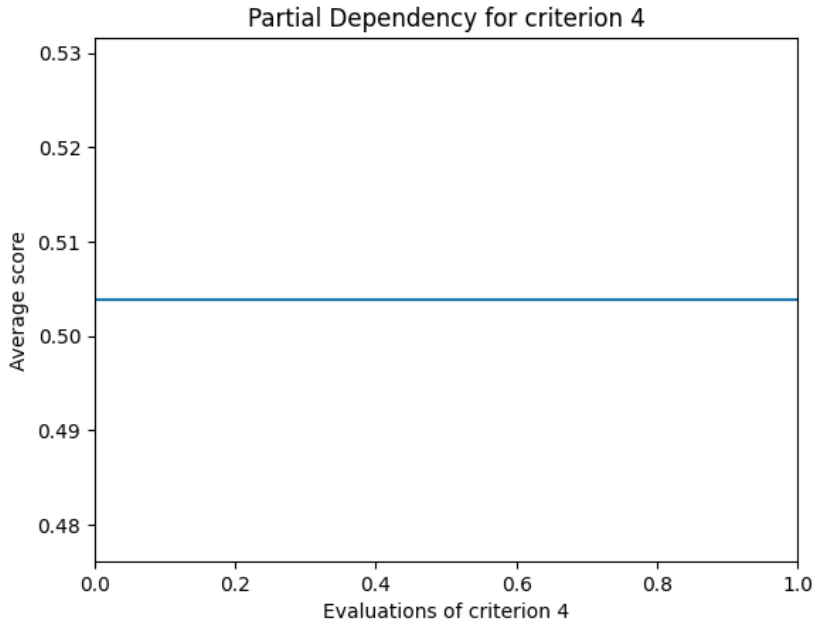
Partial Dependency for criterion 4
Average score
0.53
0.52
0.51
0.50
0.49
0.48
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 4

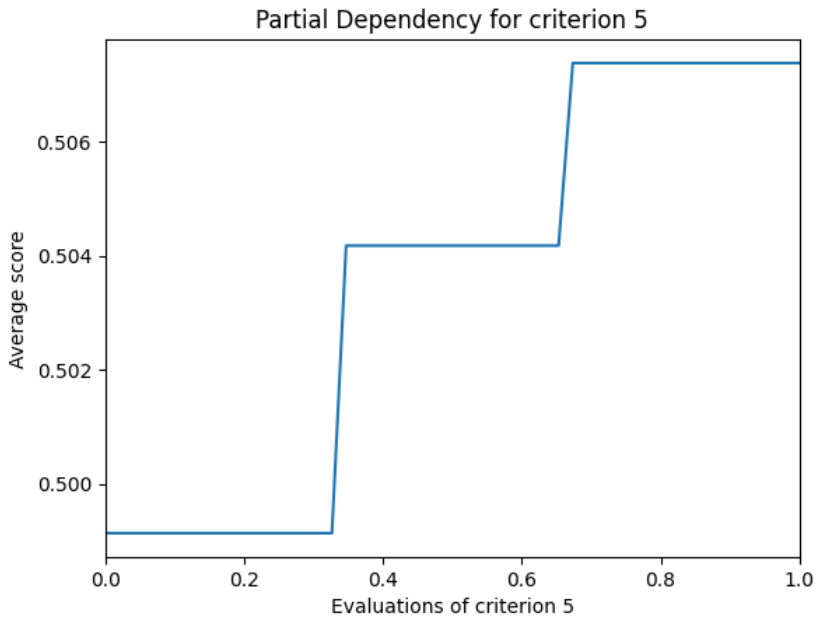
Partial Dependency for criterion 5
Average score
0.506
0.504
0.502
0.500
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 5

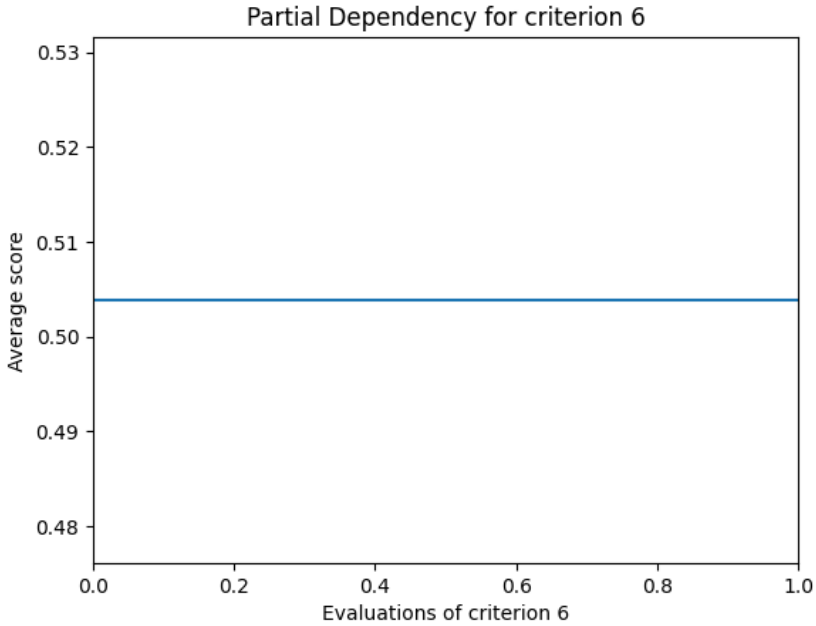
Partial Dependency for criterion 6
Average score
0.53
0.52
0.51
0.50
0.49
0.48
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 6

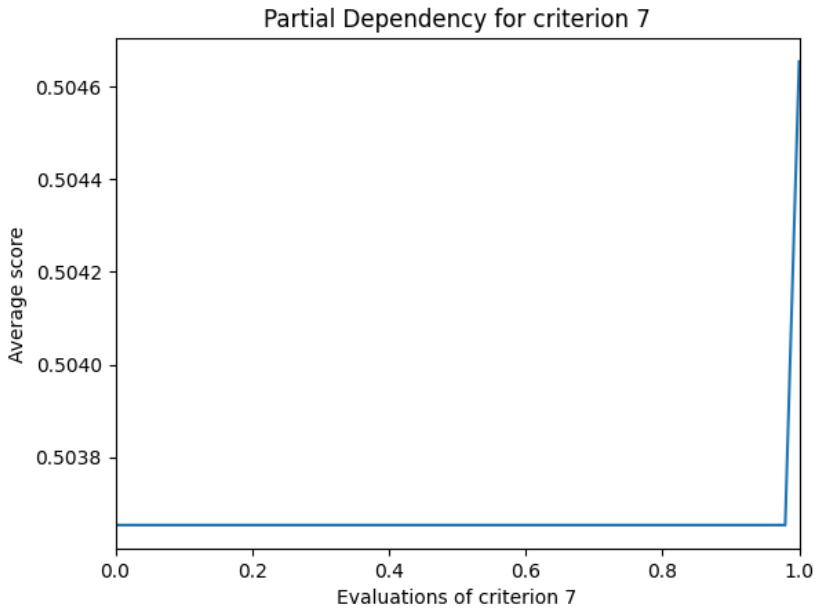
Partial Dependency for criterion 7
Average score
0.5046
0.5044
0.5042
0.5040
0.5038
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 7

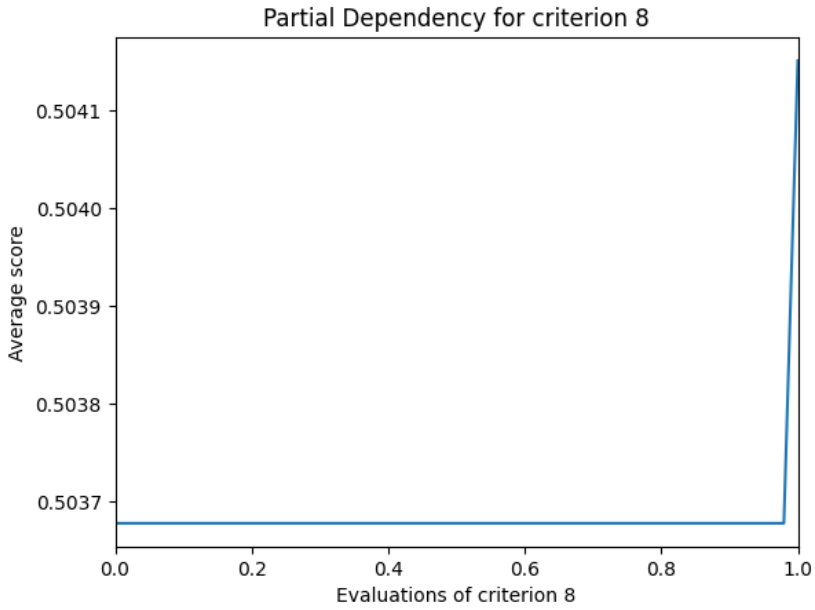
Partial Dependency for criterion 8
Average score
0.5041
0.5040
0.5039
0.5038
0.5037
0.0
0.2
0.4
0.6
0.8
1.0
Evaluations of criterion 8

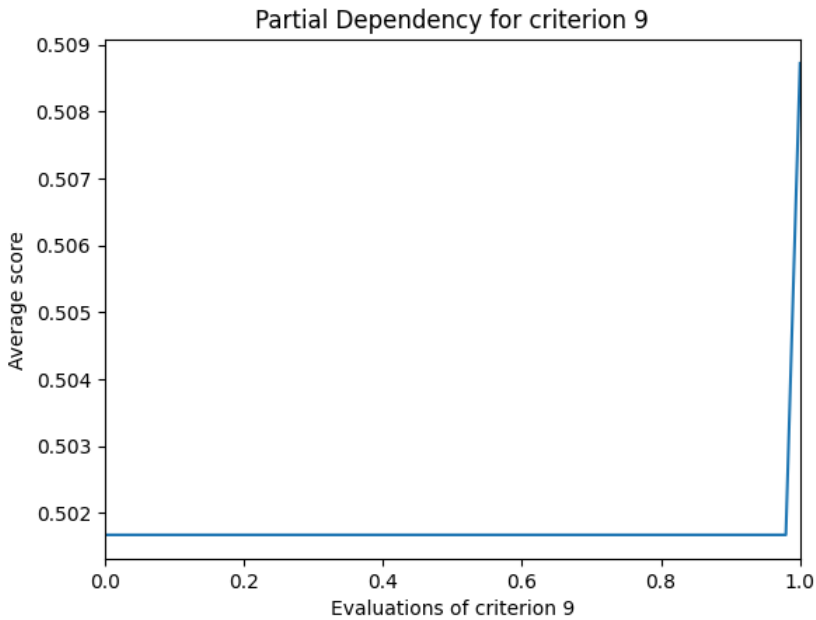

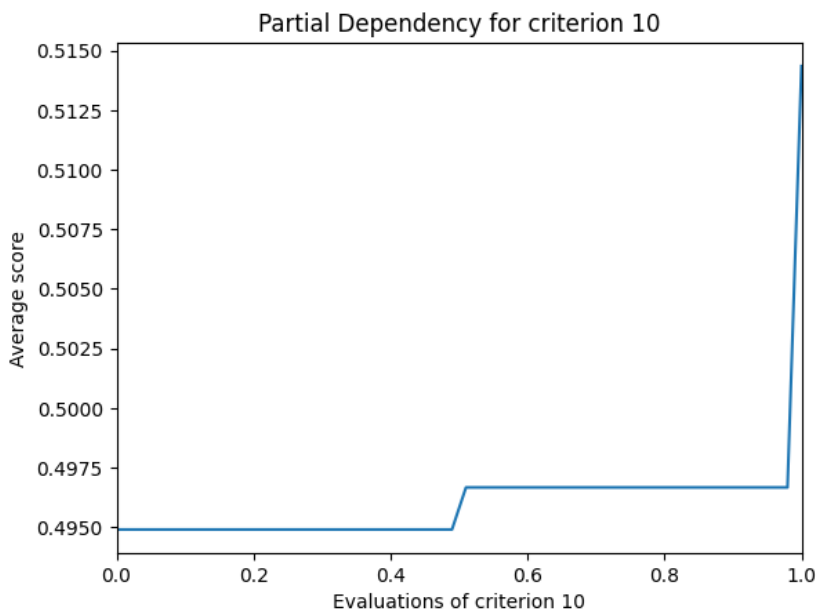

Analiza modelu XGBoost została przeprowadzona z wykorzystaniem wykresów zależności częściowej (Partial Dependence Plots). Pozwalają one na zbadanie marginalnego wpływu poszczególnych kryteriów na prawdopodobieństwo przynależności wariantu do klasy pozytywnej (klasa 1), przy uśrednieniu wpływu pozostałych parametrów.

Na podstawie uzyskanych wyników oraz parametrów modelu można jednoznacznie określić charakter preferencji odzwierciedlonych w danych: Ze względu na nałożone więzy monotoniczności (monotone_constraints), wszystkie kryteria mają charakter zysku.

Wykresy PDP dla każdego z 10 kryteriów są funkcjami niemalejącymi. Oznacza to,

że wzrost oceny na dowolnym kryterium nigdy nie obniża prawdopodobieństwa akceptacji wariantu.

W modelu nie występują kryteria typu koszt ani niemonotoniczne kryteria.

Największy wpływ na wynik modelu wykazują kryterium 10 oraz kryterium 5. Wykresy PDP dla tych cech charakteryzują się największą amplitudą zmian prawdopodobieństwa. Przykładowo, zmiana oceny na kryterium 10 z niskiej na wysoką potrafi drastycznie zmienić predykcję modelu, co czyni je kluczowym czynnikiem dyskryminującym.

Kryteria, dla których wykresy PDP są relatywnie płaskie, mają drugorzędne znaczenie. W ich przypadku zmiana oceny (nawet o znaczną wartość) tylko nieznacznie modyfikuje szansę na klasyfikację pozytywną.

Zastosowanie modelu opartego na jednym drzewie decyzyjnym (n_estimators: 1) skutkuje schodkowym charakterem wykresów PDP, co pozwala na identyfikację konkretnych progów:

Poziome odcinki na wykresach PDP wskazują na zakresy ocen, które są nierozróżnialne z punktu widzenia preferencji. Jeśli dwie różne wartości oceny (np. 0.4 i 0.6) leżą na tym samym stopniu schodka, oznacza to, że model przypisuje im identyczną użyteczność, a różnica między nimi nie wpływa na końcową decyzję.

2. UTADIS

2.1 Wizualizacja modelu (Marginal utility functions)

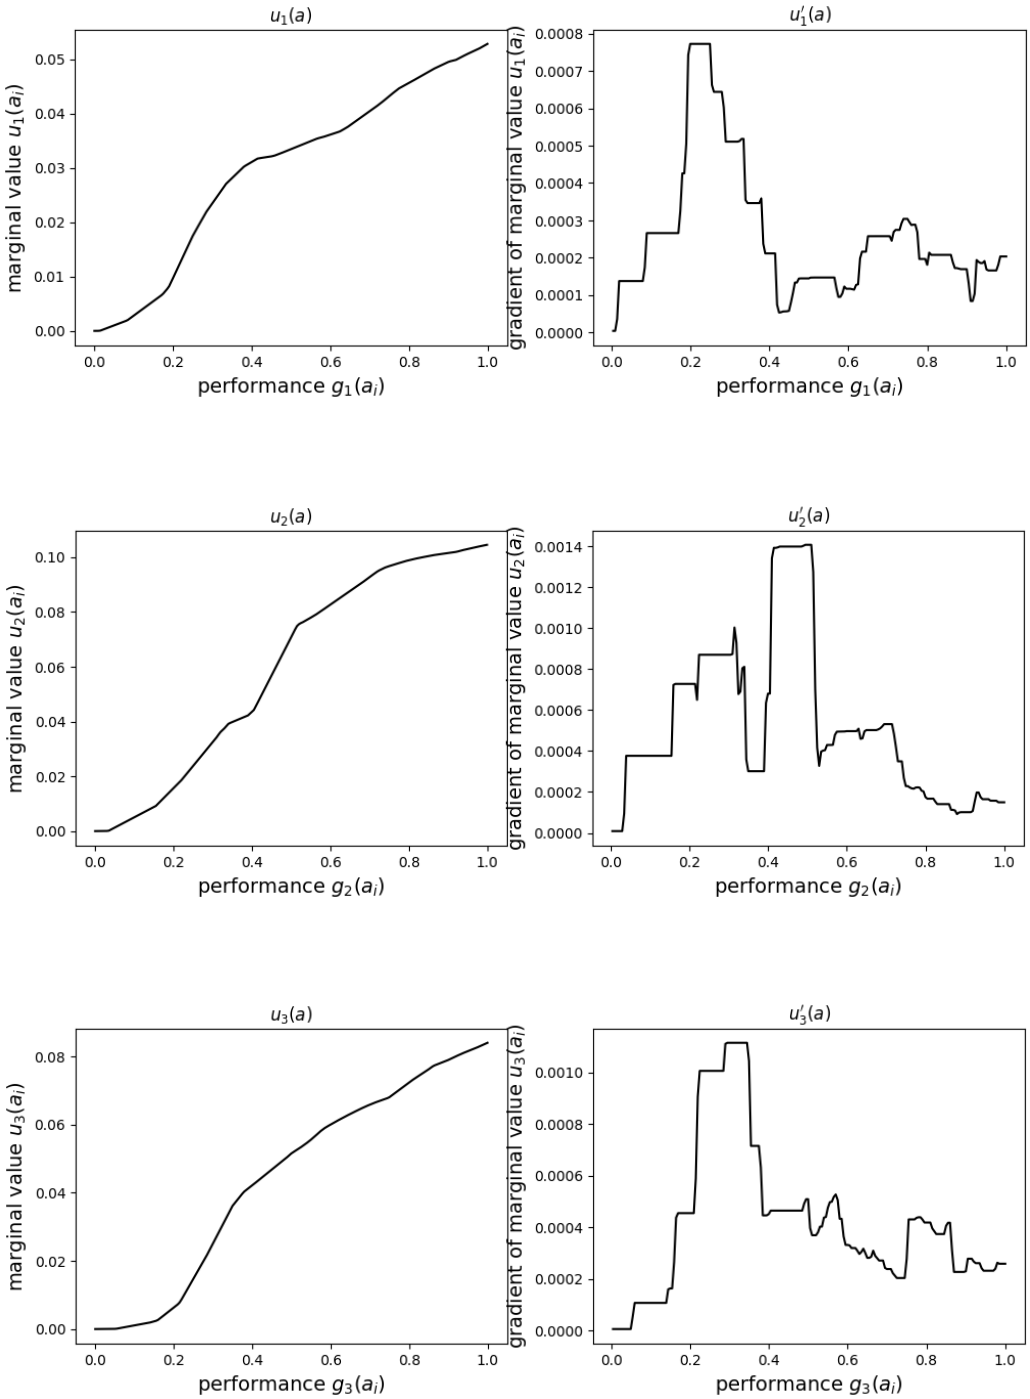

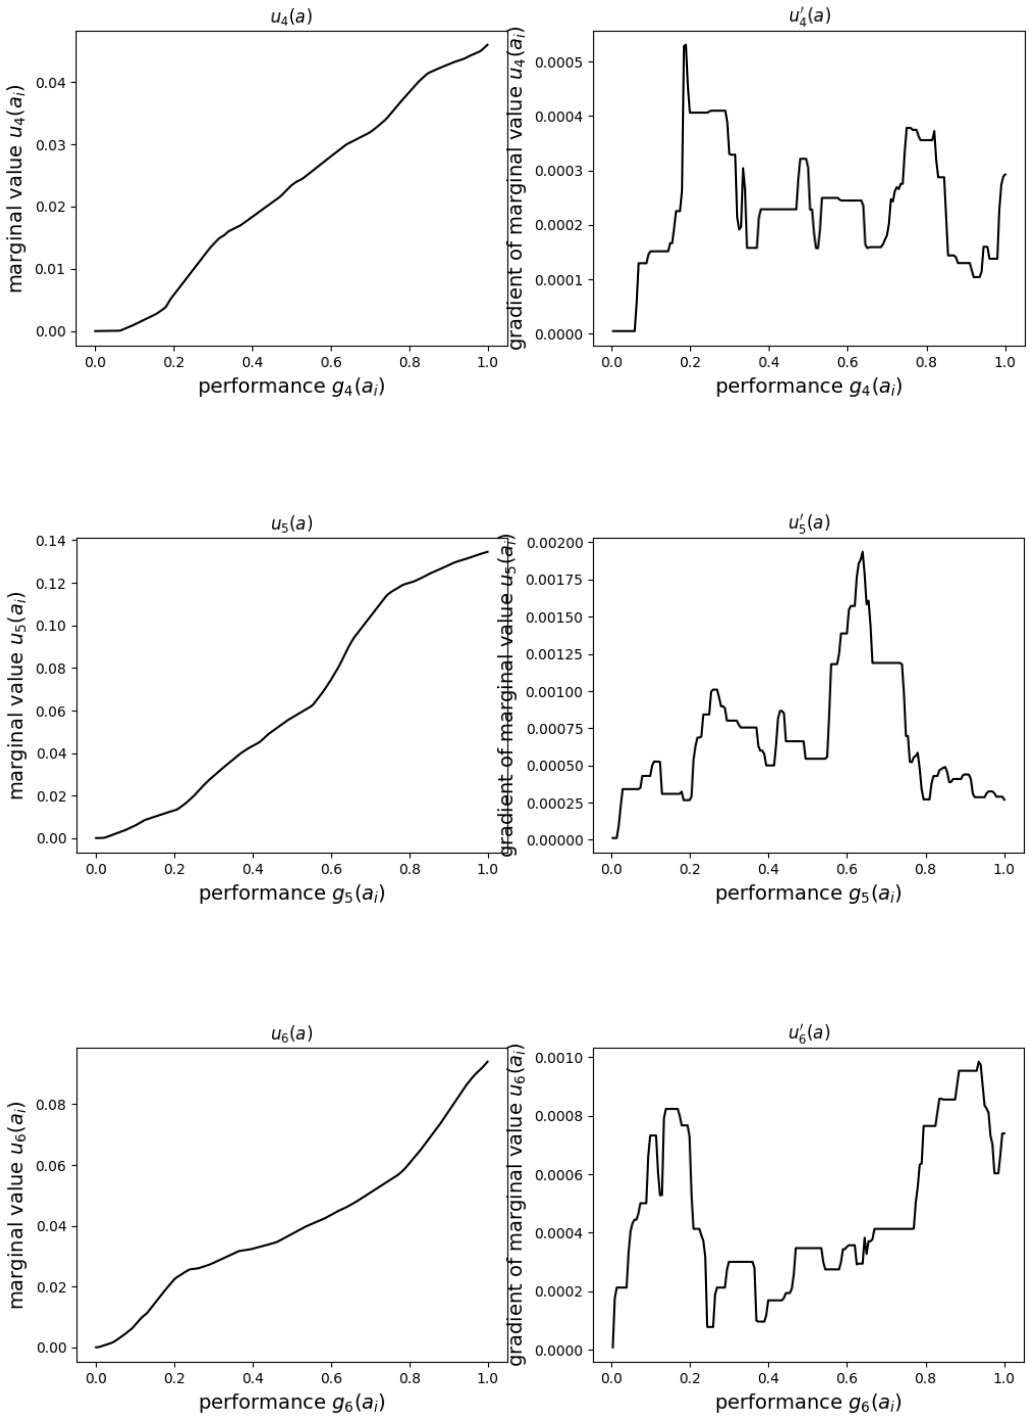
$u_4(a)$
marginal value $u_4(a_i)$
performance $g_4(a_i)$
$u_4'(a)$
gradient of marginal value $u_4(a_i)$
performance $g_4(a_i)$
$u_5(a)$
marginal value $u_5(a_i)$
performance $g_5(a_i)$
$u_5'(a)$
gradient of marginal value $u_5(a_i)$
performance $g_5(a_i)$
$u_6(a)$
marginal value $u_6(a_i)$
performance $g_6(a_i)$
$u_6'(a)$
gradient of marginal value $u_6(a_i)$
performance $g_6(a_i)$

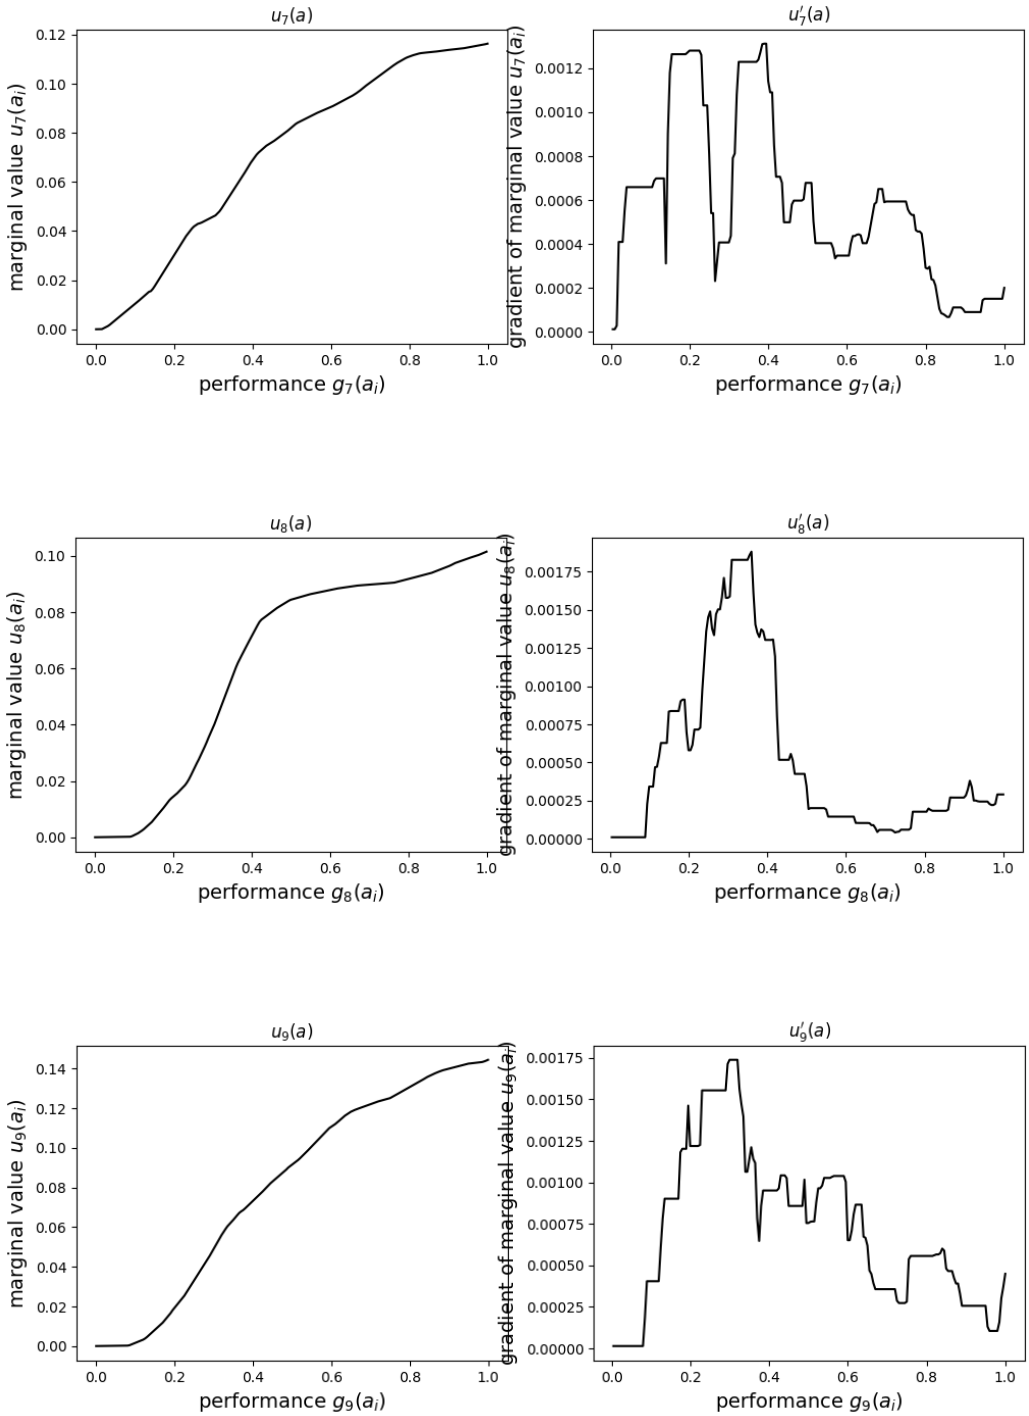
$u_7(a)$
marginal value $u_7(a_i)$
performance $g_7(a_i)$
$u'_7(a)$
gradient of marginal value $u_7(a_i)$
performance $g_7(a_i)$
$u_8(a)$
marginal value $u_8(a_i)$
performance $g_8(a_i)$
$u'_8(a)$
gradient of marginal value $u_8(a_i)$
performance $g_8(a_i)$
$u_9(a)$
marginal value $u_9(a_i)$
performance $g_9(a_i)$
$u'_9(a)$
gradient of marginal value $u_9(a_i)$
performance $g_9(a_i)$

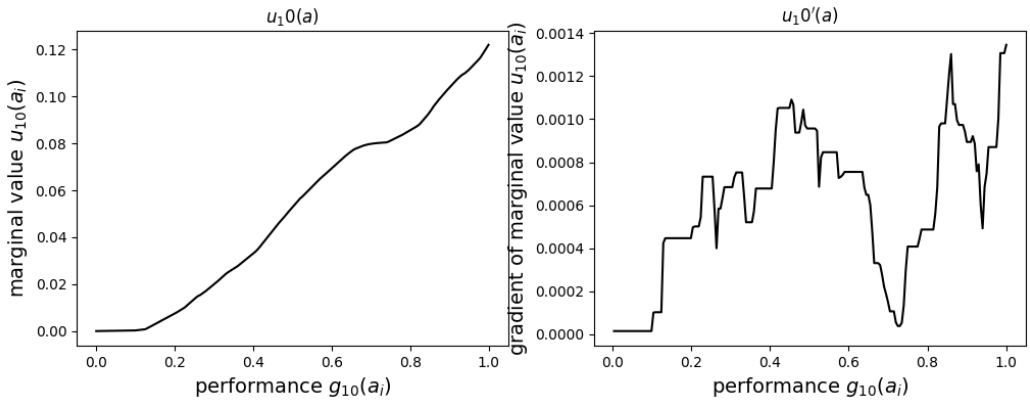

#	1	2	3	4	5	6	7	8	9	10
1	1.0	0.0	0.3333	0.0	0.6667	1.0	0.5	1.0	0.5	0.5
2	0.0	1.0	0.6667	0.0	1.0	1.0	0.0	0.0	0.5	1.0
3	0.5	0.5	0.3333	0.5	0.3333	0.0	0.5	0.5	0.5	0.0

Table 2: Przykładowe 3 warianty wraz z ocenami na kryteriach (numery kryteriów przesunięte o 1)

Dla wariantów przedstawionych w powyższej tabeli zostały wyznaczone następujące minimalne zmiany na kryteriach dla zmiany klasy:

#	Kryterium (Guided Gradients)	Zmiana (Guided Gradients)
1	9	-0.9851
2	10	-0.2321
3	6	+0.6136

Table 3: Zmiany wartości na kryteriach dla guided gradients

#	Kryterium (próbkowanie)	Zmiana (Próbkowanie)
1	7	-0.5
2	9	-0.5
3	9	+0.1566

Table 4: Zmiany wartości na kryteriach dla próbkowania

Jak widać, próbkowanie na ogół znajduje mniejsze zmiany wartości (choć na wariancie 2 jest na odwrót). Wynika to ze specyfiki analitycznego wyznaczania zmiany ze wzoru (braku normalizacji wartości):

$$\Delta \mathbf{x}_i = \frac{th - \hat{y}}{\nabla_i \mathbf{x}_i}$$

2.2 Metryki

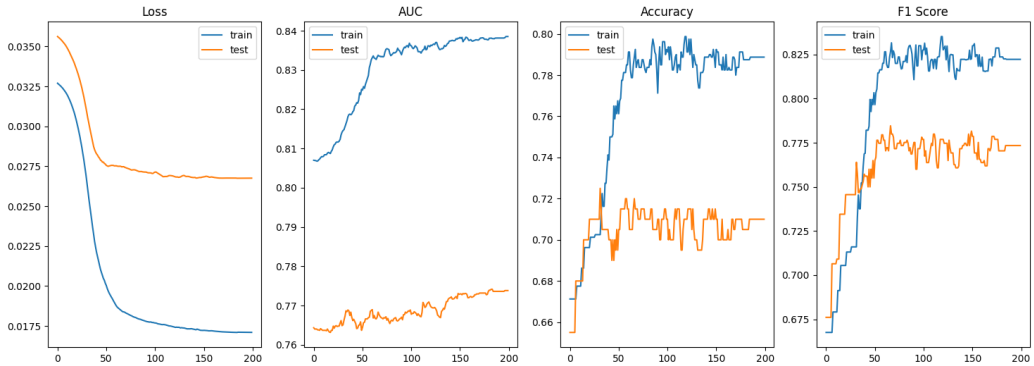

2.3 Interpretacja

Funkcje użyteczności cząstkowych pełnią funkcję PDP w przypadku ANN-UTADIS.

Analiza preferencji na podstawie parametrów modelu

Wyuczone parametry warstwy NormLayer pozwalają na precyzyjne odczytanie preferencji decydentów. Każda z 10 funkcji użyteczności krańcowej reprezentuje subiektywną wartość, jaką model przypisuje poszczególnym poziomom ocen na danym kryterium. Zagregowana użyteczność wariantu jest sumą tych wartości. Fakt, że model osiągnął wysoką stabilność (co widać po przebiegu funkcji krańcowych), świadczy o tym, że wyuczone parametry poprawnie oddają system wartości pracowników socjalnych zawarty w zbiorze danych.

Istotność kryterium w modelu UTADIS jest mierzona maksymalnym wkładem, jaki może ono wnieść do użyteczności globalnej (rozpiętość funkcji od 0.0 do 1.0).

Na podstawie wykresów funkcji użyteczności, najbardziej wpływowymi parametrami są Kryterium 10 oraz Kryterium 8 i 9. Ich funkcje osiągają najwyższe wartości końcowe, co oznacza, że wysoka ocena na tych kryteriach jest w stanie samodzielnie przesunąć wariant powyżej progu akceptacji.

Kryteria takie jak 2 czy 4 wykazują bardzo małą rozpiętość pionową. Oznacza to, że ich wpływ na końcową decyzję jest marginalny.

Wszystkie 10 kryteriów ma charakter zysku. Funkcje użyteczności są niemalejące, co oznacza, że wyższa ocena na kryterium zawsze skutkuje taką samą lub wyższą użytecznością globalną.

Progi preferencji są widoczne tam, gdzie funkcja gwałtownie rośnie (stromy nachylenie). Przykładowo, na kryterium 10 widać wyraźny skok użyteczności w okolicach wartości 0.5-0.7. Jest to próg preferencji – po jego przekroczeniu wariant zyskuje w oczach decydenta znacznie więcej niż przy wzroście w innych zakresach.

Oceny nierozróżnialne występują na płaskich odcinkach funkcji. Jeśli funkcja jest pozioma (np. na początku skali dla niektórych kryteriów), oznacza to, że dla decydenta wszystkie oceny w tym zakresie są nierozróżnialne. Różnica między oceną 0.0 a 0.2 na takim kryterium nie zmienia statusu wariantu, co sugeruje istnienie progu dolnego, poniżej którego warianty są traktowane jako jednakowo słabe.

3. Sieć neuronowa MLP (Blackbox)

3.1 Wizualizacja

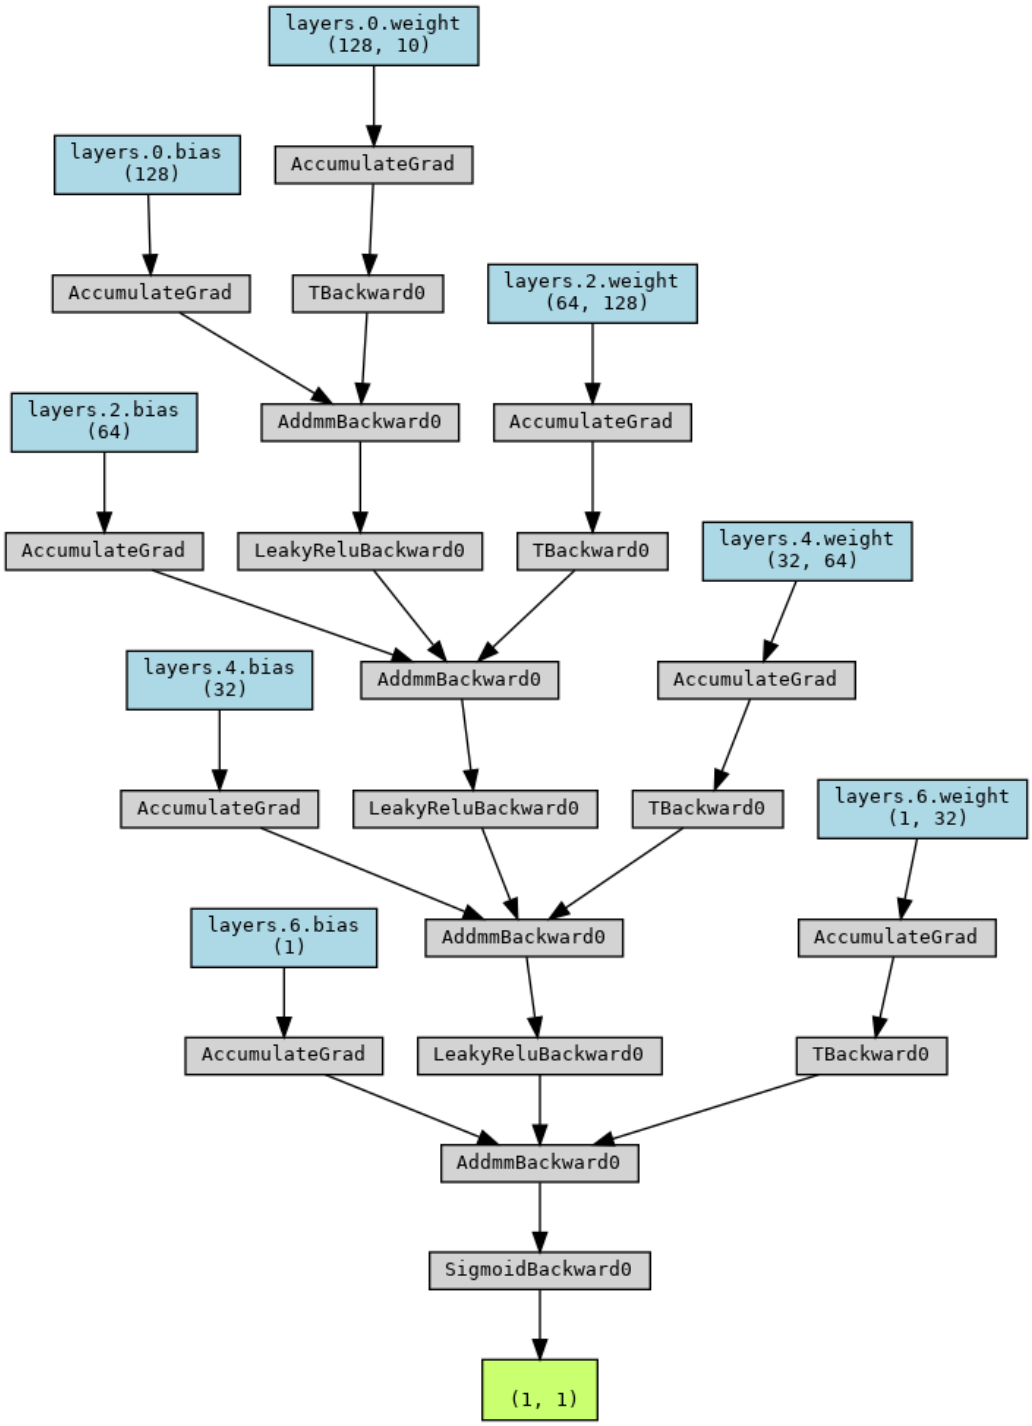

Figure 3: Wizualizacja sieci

3.2 Metryki

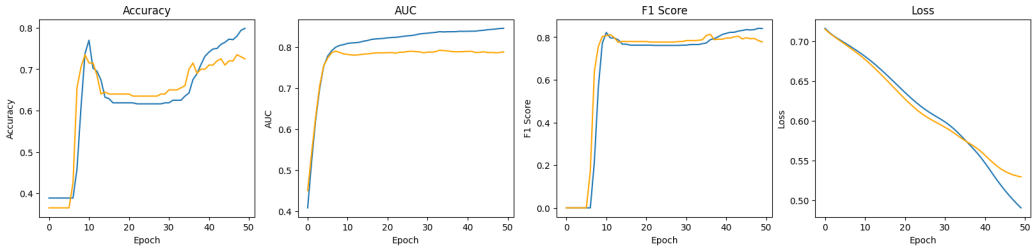

3.3 Wyjaśnienie decyzji

#	Kryterium (Guided Gradients)	Zmiana (Guided Gradients)
1	3	-0.1
2	3	-0.3
3	2	-1.0

Table 5: Zmiany wartości na kryteriach dla guided gradients

#	Kryterium (próbkowanie)	Zmiana (Próbkowanie)
1	3	-0.3333
2	3	-0.3333
3	2	-1.0

Table 6: Zmiany wartości na kryteriach dla próbkowania

W tym przypadku obie metody zwracają te same wyniki dla minimalnych zmian na pojedynczym kryterium.

3.4 Interpretacja modelu

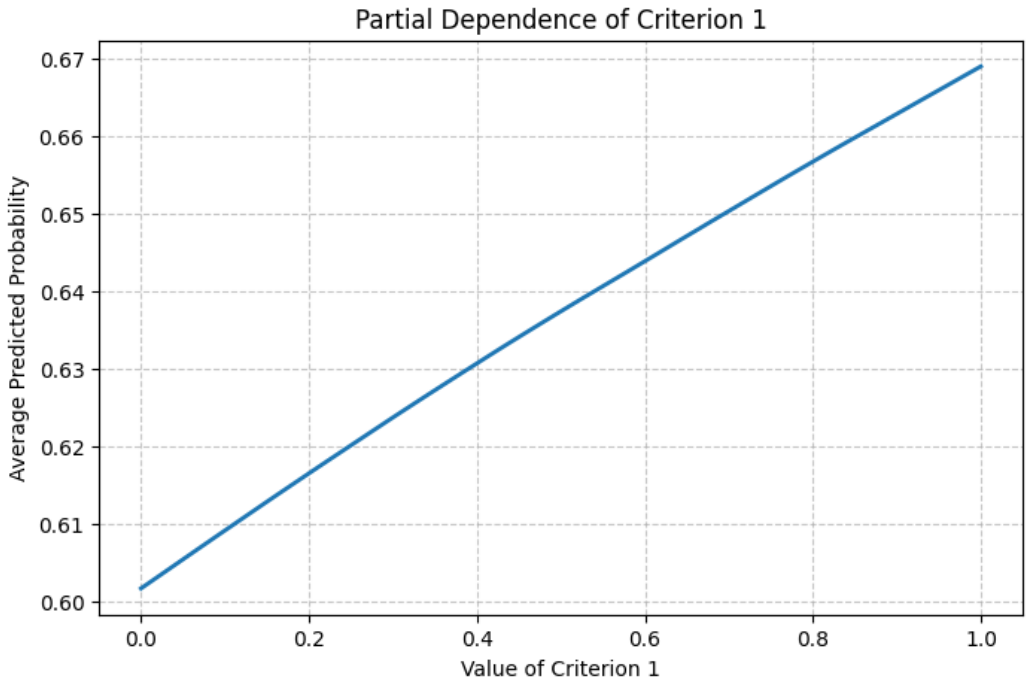

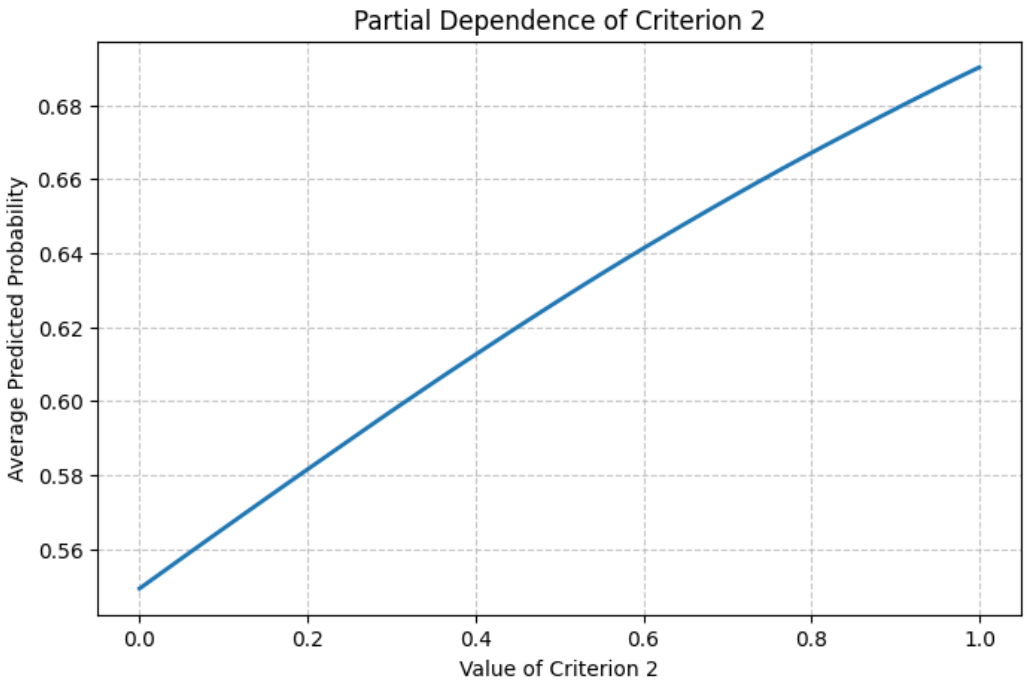

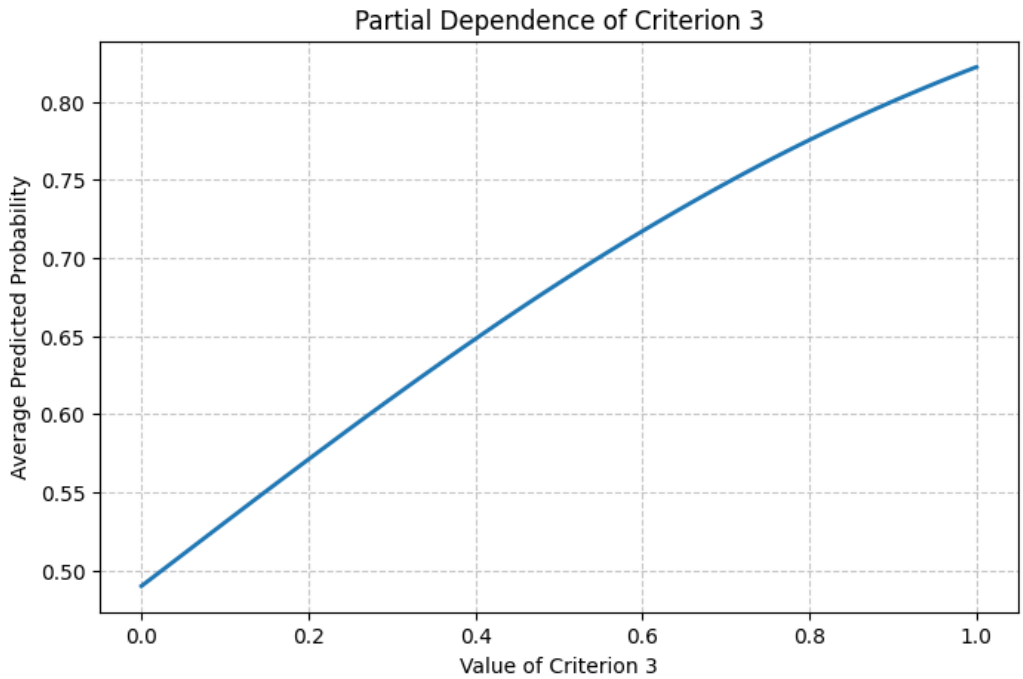
Partial Dependence of Criterion 3
Average Predicted Probability
0.80
0.75
0.70
0.65
0.60
0.55
0.50
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 3

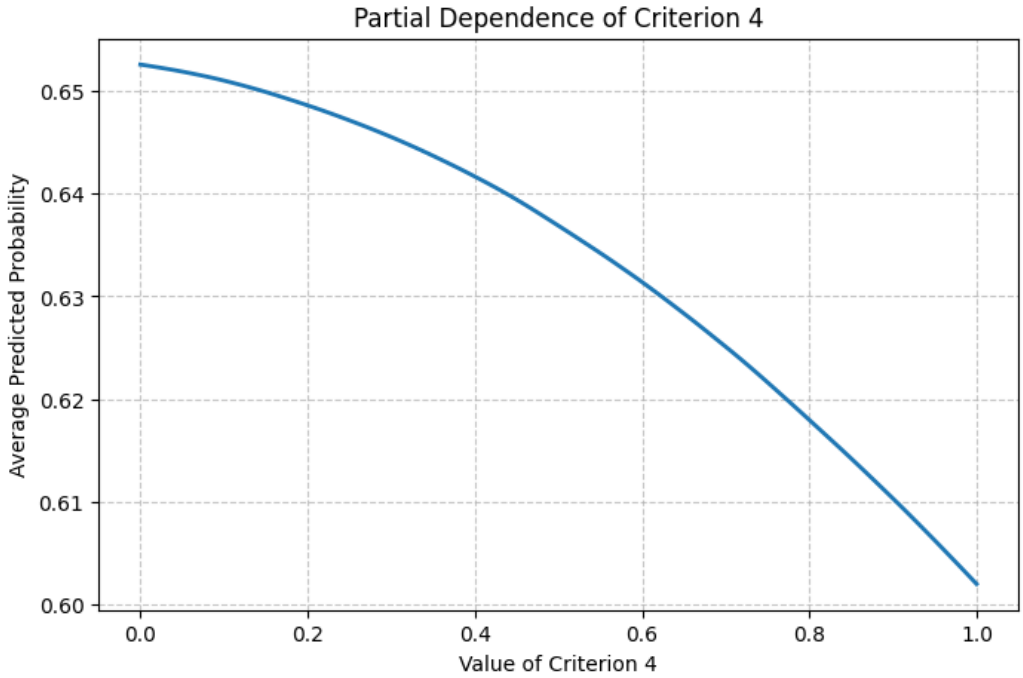
Partial Dependence of Criterion 4
Average Predicted Probability
0.65
0.64
0.63
0.62
0.61
0.60
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 4

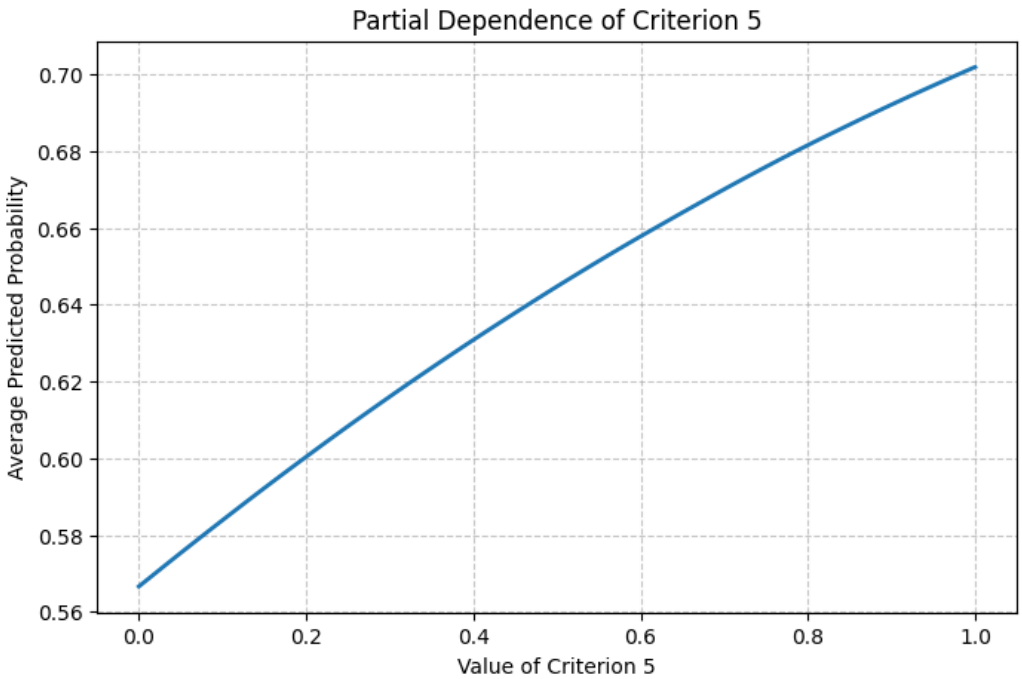
Partial Dependence of Criterion 5
Average Predicted Probability
0.70
0.68
0.66
0.64
0.62
0.60
0.58
0.56
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 5

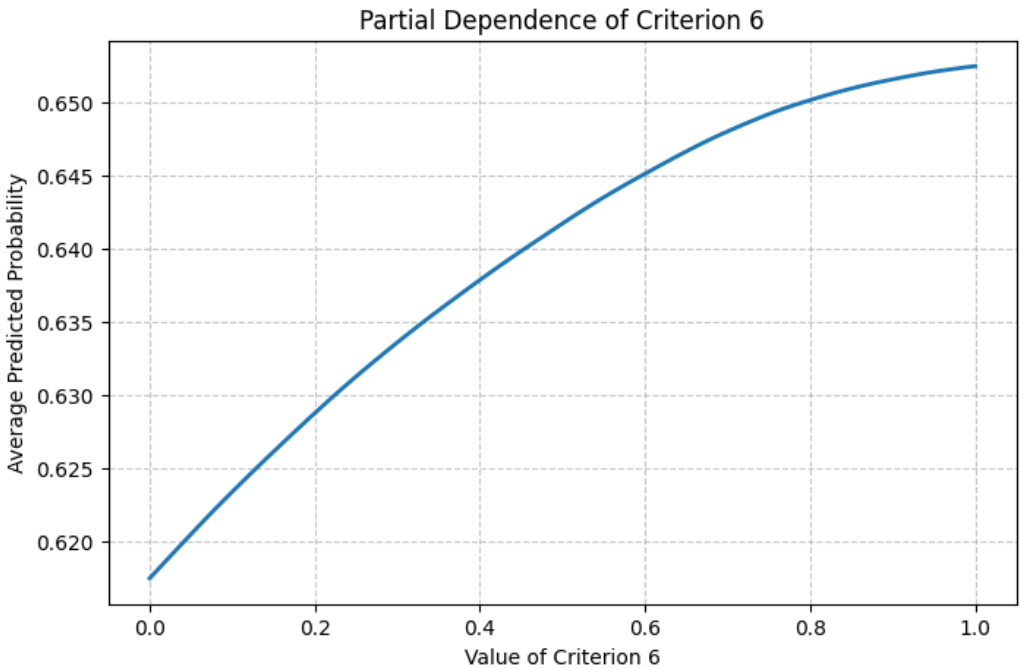
Partial Dependence of Criterion 6
Average Predicted Probability
0.650
0.645
0.640
0.635
0.630
0.625
0.620
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 6

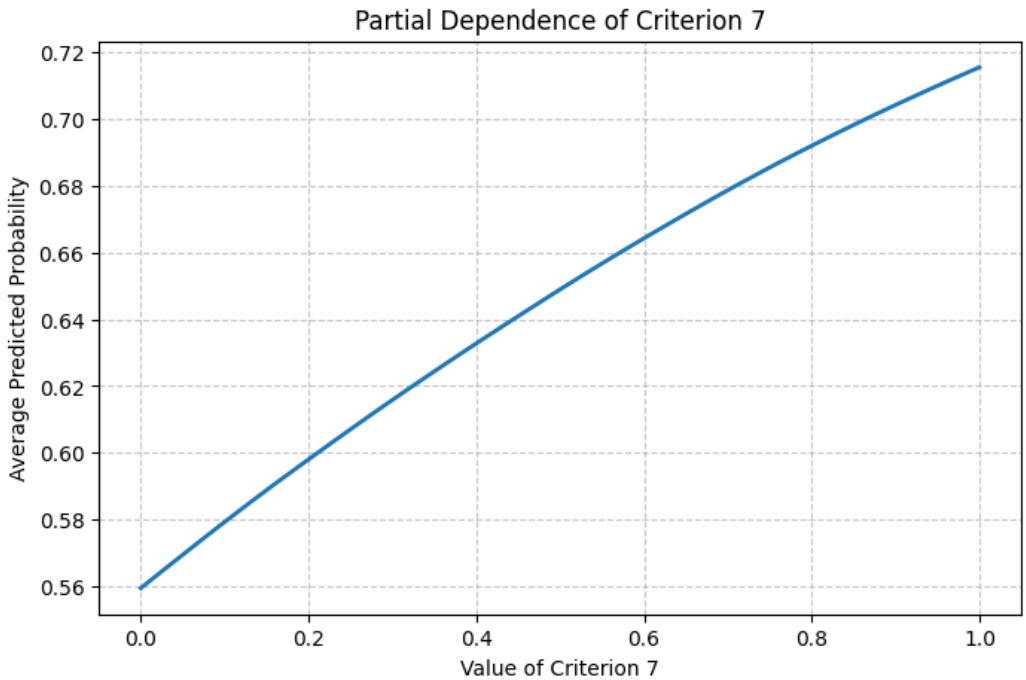
Partial Dependence of Criterion 7
Average Predicted Probability
0.72
0.70
0.68
0.66
0.64
0.62
0.60
0.58
0.56
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 7

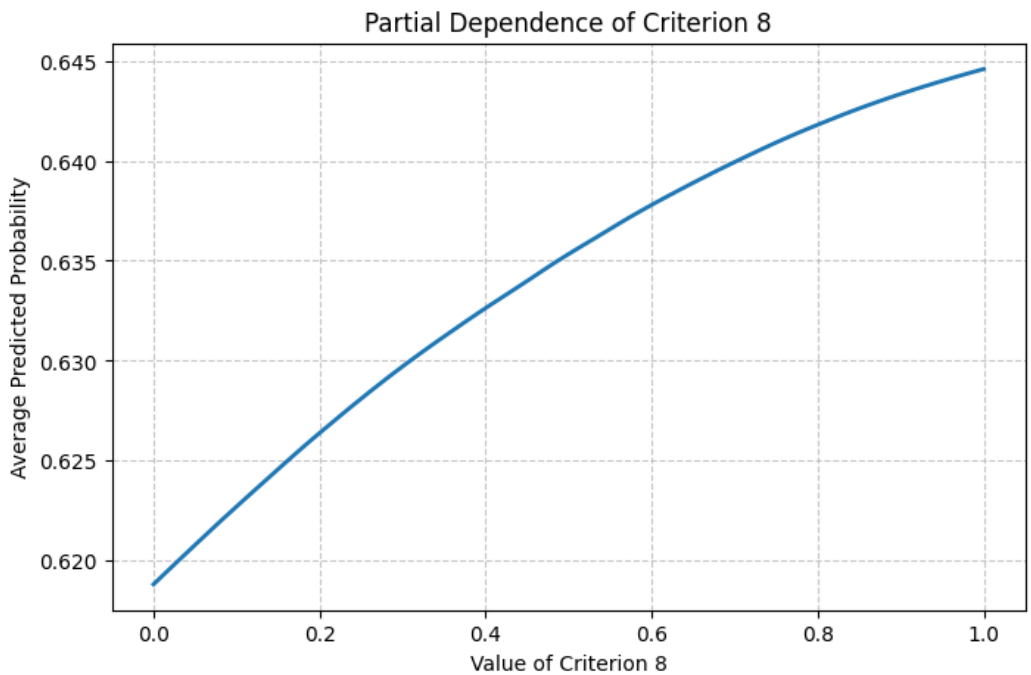
Partial Dependence of Criterion 8
Average Predicted Probability
0.645
0.640
0.635
0.630
0.625
0.620
0.0
0.2
0.4
0.6
0.8
1.0
Value of Criterion 8

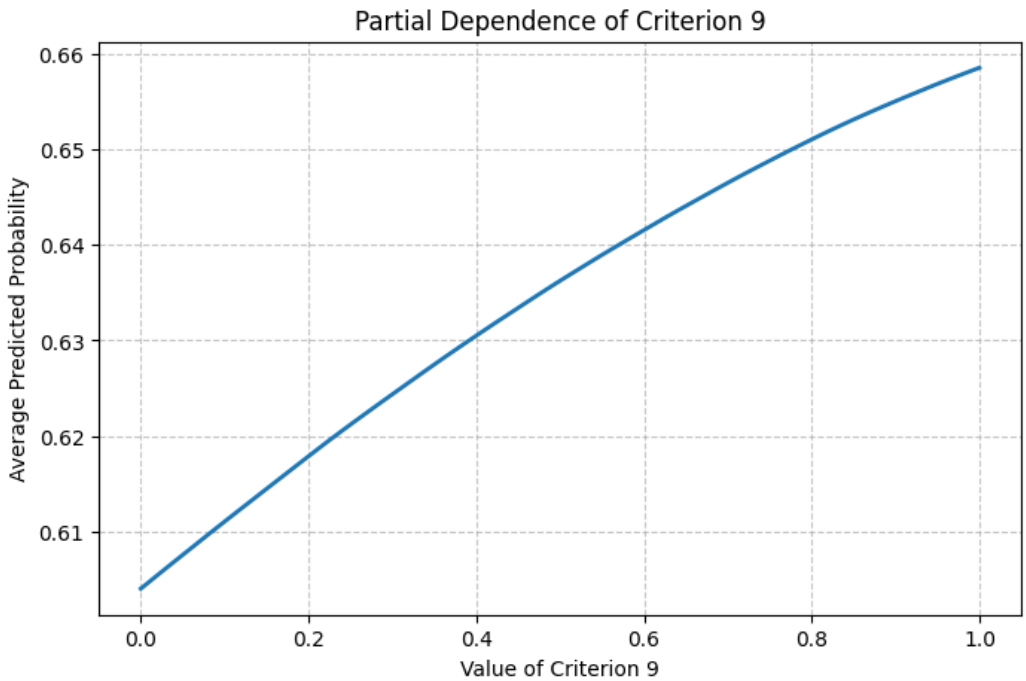

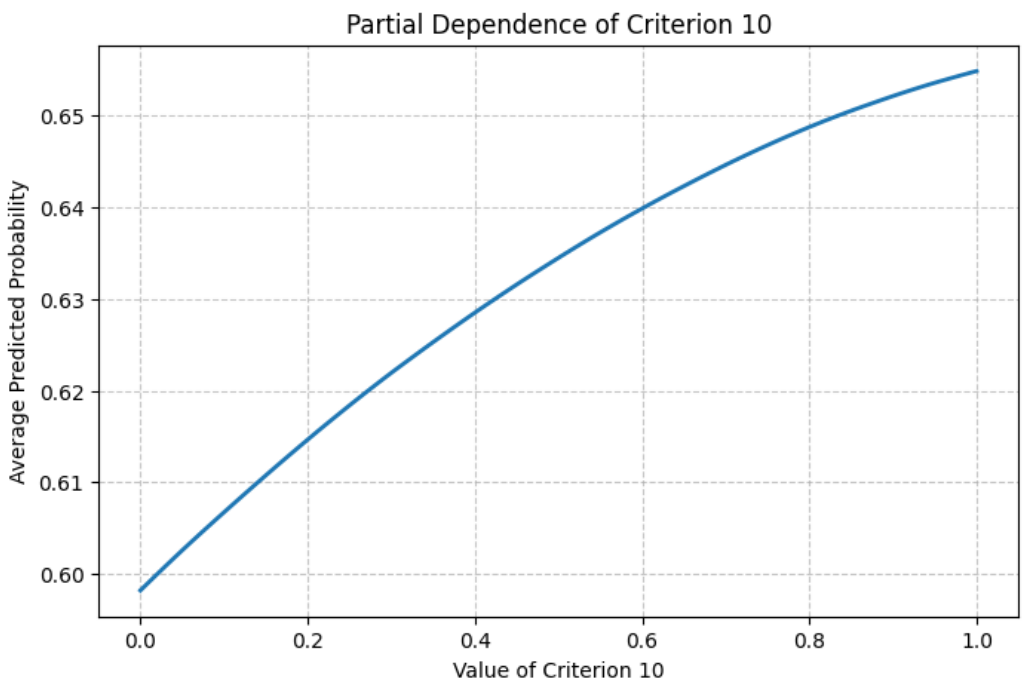

W przypadku MLP parametry są nieinterpretowalne dla człowieka. Jednak można przeprowadzić analizę na podstawie PDP.

Siłę wpływu kryterium w MLP oceniamy po nachyleniu i amplitudzie wykresu PDP:

Podobnie jak w poprzednich modelach, najwyższą amplitudę zmian prawdopodobieństwa obserwujemy dla Kryterium 9 i 10. Jednak w MLP wpływ ten często nie jest liniowy – model może być niemal niewrażliwy na kryterium w zakresie 0.0-0.4, by gwałtownie zwiększyć prawdopodobieństwo sukcesu po przekroczeniu wartości 0.5.

Wiele kryteriów (np. 1, 2, 4) na wykresach PDP MLP wykazuje bardzo małe wahania średniej odpowiedzi (np. w zakresie 0.61–0.64). Oznacza to, że sieć neuronowa uznała te cechy za mało istotne dla końcowego wyniku klasyfikacji.

Dla większości kluczowych kryteriów (jak Crit 3 czy 10), MLP zachowuje charakter zysku, ale krzywe są często przypominają funkcje sigmoidalne. Oznacza to istnienie obszarów, gdzie wpływ kryterium jest tłumiony. Co ciekawe, to na kryterium 4 jego PDP jest malejące, so sugeruje jego przynależność do typu koszt.

W MLP progi preferencji przybierają postać stref przejścia. Stroma część krzywej PDP wskazuje zakres, w którym decydent jest najbardziej wrażliwy na zmianę oceny.

Na wykresach PDP MLP widać je jako płaskie regiony na końcach lub początku skali. Jeśli linia jest pozioma w zakresie 0.0-0.3, oznacza to, że dla sieci neuronowej każda ocena niedostateczna jest traktowana tak samo – model nie widzi różnicy jakościowej między bardzo słabym a przeciętnym wynikiem na tym kryterium.